

RAG として AIChatBot に 与えるデータベースの 構造に関する一考察

*On Database Structures for
Retrieval-Augmented Generation
in AI Chatbots*

神奈川工科大学
川越 航太



概要 (Overview)

- RAG とベクトル DB の概要
- データセット & ファイル形式
- 比較実験: 設定と結果
- 考察・結論と今後の課題

研究背景と目的

1 目的 (Goal)

- RAGベースのAIチャットボットを構築し、顧客の質問に自動回答してサポート業務を効率化する。
- 応答ログを活用した、新人オペレーター等の社内教育への活用。


2 背景 (Background)

- オペレーターと顧客のやり取り、ユーザマニュアルなどから自動生成したFAQを、LLMが正確にリトリーブするためにどうすればよいか。

3 データ提供元

- 日本のEdTech企業で職能団体・学会・自治体などの研修をオンライン／オフライン問わず一元管理できる「研修DXプラットフォーム」を提供。

RAGシステムのフロー



大規模言語モデルは外部知識ベースから関連情報を検索し、回答生成に活用する。

RAG (Retrieval-Augmented Generation) は、クエリに対してベクトルデータベースから類似文書を検索し、LLM へ渡して応答を生成する仕組み。

本研究では FAQ データセット (100件/1000件) を複数形式に変換し、VDB 化して検索精度を評価した。

データセットとファイル形式



DOCX



PDF



TXT

非構造化データ



CSV



XML



JSON




JSONL

構造化データ

形式	抽出ライブラリ	分割単位	メタデータ
DOCX	python-docx	段落	ファイル名+段落番号
PDF	PyPDF2	ページ	ファイル名+ページ
TXT	open().read	全文	ファイル名
CSV	pandas.read_csv	行	ファイル名+行番号
XML	xml.etree	エントリ要素	ファイル名+エントリ番号
JSON	json.load	オブジェクト	ファイル名+エントリ番号
JSONL	json.loads	行	ファイル名+行番号

前処理パイプライン



- チャンク長: 1000 文字, オーバーラップ: 200 文字
- 埋め込みモデル: `intfloat/multilingual-e5-large`
- 使用ライブラリ:  LlamaIndex
- 言語モデル:  Gemini 2.0-flash

非構造化データのVDB化の例

 チャンク

 オーバーラップ

Question: 管理者側から受講者を申し込んだ場合、受講者には申込み完了のメールが送信されますか？

Answer: 管理者側からの申込みでも、申込フォームの「メール設定」タブで送信設定をしている場合は、受講者側・管理者側のどちらが申し込んでもメールが送信されます。

Question: レッスンに紐づく課題の回答ボタンが表示されません。どの受講状況で回答可能になりますか？

Answer: 基本的に「受講予定」になると課題に回答できるようになります。ただし、特定の研修では、レッスンが「受講完了」になってから課題に回答できる設定がされている場合があります。

Question: 課題をダウンロードすると、受講者が作成したファイル名ではなく、別の名前でダウンロードされます。どこで設定を変更すれば、アップロードされたファイル名でダウンロードできますか？

Answer: 現在の仕様では、ダウンロード時にランダムなファイル名が割り当てられます。仕様改善が進められていますので、改善までお待ちいただければと思います。

構造化データの VDB化の例

 質問

 回答

```
[  
  {  
    "question": "管理者側から受講者を申し込んだ場合、受講者には  
    申し込み完了のメールが送信されますか？",  
    "answer": "管理者側からの申し込みでも、申込フォームの  
    「メール設定」タブで送信設定をしている場合は、受講者側・  
    管理者側のどちらが申し込んでもメールが送信されます。",  
  },  
  {  
    "question": "レッスンに紐づく課題の回答ボタンが表示されま  
    せん。どの受講状況で回答可能になりますか？",  
    "answer": "基本的に「受講予定」になると課題に回答できる  
    ようになります。ただし、特定の研修では、レッスンが「受講  
    完了」になってから課題に回答できる設定がされている場合が  
    あります。",  
  },  
]
```


ファイルの内容と構造例

DOCX

Question: IT サービス契約において、クラウドサーバーの管理画面からサーバーの管理を依頼する手順を教えてください。

Answer: 管理画面の「サーバー管理」メニューから「サーバーの管理」ボタンをクリックしてください。変更後の構成は自動的に計算されます。

Question: 銀行口座を開設する際に必要な書類は何ですか？

Answer: 本人確認書類として運転免許証またはマイナンバーカード（3 カ月以内発行）、およびマイナンバー通知カードが必要です。なお、未成年の場合は戸籍抄本と親権者の同意書も必要です。

Question: 病院で健康診断を受けた後、結果はどのようにして通知されますか？

Answer: 診断結果は受診後約 1 週間で Web ポータルサイトの「検査結果」から PDF 形式でダウンロード可能です。また、メールアドレスにも通知が届きます。

JSON

```
{  
  "question": "ITサービス契約において、クラウドサーバーの管理画面からサーバーの管理を依頼する手順を教えてください。",  
  "answer": "管理画面の「サーバー管理」メニューから「サーバーの管理」ボタンをクリックしてください。変更後の構成は自動的に計算されます。",  
},  
{  
  "question": "銀行口座を開設する際に必要な書類は何ですか？",  
  "answer": "本人確認書類として運転免許証またはマイナンバーカード（3 カ月以内発行）、およびマイナンバー通知カードが必要です。なお、未成年の場合は戸籍抄本と親権者の同意書も必要です。",  
},  
{  
  "question": "病院で健康診断を受けた後、結果はどのようにして通知されますか？",  
  "answer": "診断結果は受診後約1週間でWebポータルサイトの「検査結果」からPDF形式でダウンロード可能です。また、メールアドレスにも通知が届きます。",  
},  
{  
  "question": "大学の入学手続きでは、入学許可通知書を送付する際に必要な書類は何ですか？",  
  "answer": "入学許可通知書送付後から30日以内に入学許可通知書を送付する必要があります。",  
},  
{  
  "question": "ネット通販サイトで購入した商品の返品ポリシーを確認する方法はありますか？",  
  "answer": "商品到着後7日以内で未開封・未使用の商品であれば、返品が可能です。",  
},  
}
```

CSV

question	answer
ITサービス契約において、クラウドサーバーの管理画面からサーバーの管理を依頼する手順を教えてください。	管理画面の「サーバー管理」メニューから「サーバーの管理」ボタンをクリックしてください。変更後の構成は自動的に計算されます。
銀行口座を開設する際に必要な書類は何ですか？	本人確認書類として運転免許証またはマイナンバーカード（3 カ月以内発行）、およびマイナンバー通知カードが必要です。なお、未成年の場合は戸籍抄本と親権者の同意書も必要です。
病院で健康診断を受けた後、結果はどのようにして通知されますか？	診断結果は受診後約1週間でWebポータルサイトの「検査結果」からPDF形式でダウンロード可能です。また、メールアドレスにも通知が届きます。
大学の入学手続きでは、入学許可通知書を送付する際に必要な書類は何ですか？	入学許可通知書送付後から30日以内に入学許可通知書を送付する必要があります。
ネット通販サイトで購入した商品の返品ポリシーを確認する方法はありますか？	商品到着後7日以内で未開封・未使用の商品であれば、返品が可能です。


各形式に応じたチャンク構造:

DOCX は段落単位、CSV は行単位、JSON はオブジェクト単位に分割される。100問はEdTech企業からの提供データ、+900問はそれを基にOpenAI o3で拡張したデータ。

実験設定① 100 問に対する10問の質問

1	管理者側から受講者を申し込んだ場合、受講者には申込み完了のメールが送信されますか？
2	クレジットカード払いでキャンセルした場合、返金はいつ頃になりますか？
3	代表者アカウントのメンバー画面で「メンバー情報変更」と「アカウントの削除」を制限するにはどうすれば良いですか？
4	修了証はどのようにダウンロードできますか？
5	コースの言語設定を変更できますか？
6	受講者の進捗状況を一括で更新できますか？
7	システムメンテナンス情報はどこで確認できますか？
8	講師の都合で講義の日程や順序を変更する方法を教えてください。
9	受講料の一部を振り込んだ後、残りの金額を支払う方法を教えてください。
10	振込コードを入力しなかった場合のリスクは何ですか？

100 問実験: 成功 / 失敗回数



- ・ JSON / JSONL では、全問正解 (10/10)。
- ・ DOCX は 70% (7/10) と低調。
- ・ その他の形式は 90% (9/10) の精度を示した。

考察 (100問)


- DOCX 形式は段落単位の分割が適切に働かず、レイアウトやネスト構造の影響で正答率が低下した。
- JSON / JSONL はオブジェクト/行単位に分割されたので、構造化度の高さが有利に働いた。
- PDF ・ TXT ・ CSV ・ XML は 90% と高精度。シンプルな構造が検索性能を上げた。

実験設定② 1000 問に対する10問の質問

1	レッスンに紐づく課題の回答ボタンが表示されません。どの受講状況で回答可能になりますか？
2	施設側から除名すると、管理画面上ではどうなりますか？
3	ログインセッションのタイムアウト時間を変更できますか？
4	オーダーIDのない支払いカードが生成されることがありますが、どういう場合に起こりますか？
5	二段階認証を有効化する方法は？
6	アカウントを削除（退会）したい場合は？
7	ユーザーのログイン履歴を確認できますか？
8	アップロードファイルのサイズ制限は？
9	イベント発生時のWebhook通知は設定できますか？
10	データ保持ポリシー（GDPR対応）の設定方法は？

1000 問実験: 成功 / 失敗回数

成功・失敗回数 (1000 問)




- ・ CSV が 8/10 で最高成績を維持。
- ・ 一方、JSON 系は 7/10、DOCX は 4/10 と大きく低下した。

考察 (1000問)

- データの増加に伴い、検索成功率が低下。
- 多くなったデータを3つのファイルに分割して保存したが、100問での実験の3倍以上の問題数を1つのファイルにまとめた。100問ずつに分割すれば、検索精度は高まった可能性が残る。
- ファイルのカテゴリでの分割手法を用いなくても、CSV,JSONなどの構造化データは一定の精度を維持できたので、構造化ファイルはQAシステムのRAGにとって相性が良い。

実験比較



- JSON 系は 100 問では 100% だったが 1000 問では 70% に低下。
- CSV は安定して 80% を維持し、最も堅牢であることが示された
- DOCX は大規模化で 70%→40% と急落し、**レイアウト依存性の脆弱さ**が顕在化した。

形式別の検討



レイアウトや段組み、構造化データではないので、チャンク化が難しく、大規模時に成功率が低下。



オブジェクト単位に分割でき、データ構造がしっかりと固定されていてVDB化しやすい。



全文を単一の文章として扱うため文脈が保持されるが、メタデータが少なくバリエーションに弱い。



レコード単位での分割が自然で、構造が単純なため大規模でも高精度を維持。



PyPDF2 による改行検出が不十分で、空白・タブの揺れが検索を阻害する可能性がある。



オブジェクト単位でデータを分割して管理できる。統一されたデータ構造により、安定した解析や変換が可能。

ファイル形式の違いによる失敗例と成功例

ハルシネーションについて：1000問程度では誤った回答を生成することではなく、検索が失敗した場合には、「**分からない**」と**出力**した。

課題をダウンロードすると、受講者が作成したファイル名ではなく、別の名前でダウンロードされます。どこで設定を変更すれば、アップロードされたファイル名でダウンロードできますか？

課題のダウンロードに関する設定変更方法についての情報は見つかりませんでした。【使用したファイル】
faq_output1.docx (page: 不明),
faq_output3.docx (page: 不明)

DOCXでの失敗例

課題をダウンロードすると、受講者が作成したファイル名ではなく、別の名前でダウンロードされます。どこで設定を変更すれば、アップロードされたファイル名でダウンロードできますか？

現在の仕様では、ダウンロード時にランダムなファイル名が割り当てられるため、設定を変更してアップロードされたファイル名でダウンロードすることはできません。仕様改善が進められていますので、改善をお待ちください。【使用したファイル】
faq_output1.csv (page: 不明),
faq_output3.csv (page: 不明)

CSVでの成功例

検索精度に差が生じた原因

質問部分は両方とも検索に成功しているが、DOCX形式では**質問と回答の紐付けが出来ないケース**が散見され、これが原因となって回答を探すことに失敗している。

```
qasystem-1 | > [Node f60ca1df-e11f-4f47-acab-aa55e470fdfe] [Similarity score: 0.848401] Answer: ファイルを右クリックして [共有リンクを作成] を選び、リンク設定画面で「パスワード保護」を有効にし、任意のパスワードを入力してください。リンクを受け取った相手は入力が必要になります。
qasystem-1 | > [Node 81b13df9-e0ca-4ea0-b853-0d80526d44b3] [Similarity score: 0.843327] Answer: マイページの [講師一覧] から新しく受講したい講師を選び、希望日時でレッスン予約をしてください。既存の予約がある場合はキャンセル料なしで変更が可能です。
```

```
qasystem-1 | DEBUG:llama_index.core.indices.utils:> Top 2 nodes:
qasystem-1 | > [Node 55d8b55b-6840-410a-a563-180b86638810] [Similarity score: 0.963113] Question: 課題をダウンロードすると、受講者が作成したファイル名ではなく、別の名前でダウンロードされます。どこで設定を変更すれば、アップロードされたファイル名でダウンロードできますか？
```

```
qasystem-1 | > [Node 55d8b55b-6840-410a-a563-180b86638810] [Similarity score: 0.868878] Answer: 課題は、受講者のステータスが「受講予定」に変更された時点で表示されます。支払いが完了していない場合、受講者のステータスが「受講予定」にならないため、課題は表示されません。
```

```
qasystem-1 | > [Node a73996a9-29f2-447e-8208-5da874161820] [Similarity score: 0.833109] Q: オンラインストレージで共有リンクにパスワードを設定するには？
qasystem-1 | A: ファイルを右クリックして [共有リンクを作成] を選び、リンク設定画面で「パスワード保護」を有効にし、任意のパスワードを入力...
```

```
qasystem-1 | > [Node 09502534-2e26-4f1f-8017-bb8c9316cbbb] [Similarity score: 0.828888] Q: オンライン英会話スクールで講師の変更をしたい場合は？
```

```
qasystem-1 | A: マイページの [講師一覧] から新しく受講したい講師を選び、希望日時でレッスン予約をしてください。既存の予約がある場合はキャンセル料...
```

```
qasystem-1 | > [Node b4de197f-13cb-4c88-9f6d-ef756dfd2b79] [Similarity score: 0.954508] Q: 課題をダウンロードすると、受講者が作成したファイル名ではなく、別の名前でダウンロードされます。どこで設定を変更すれば、アップロードされたファイル名でダウンロードできますか？
```

```
qasystem-1 | A: 現在の仕...
```

```
qasystem-1 | > [Node 55d8b55b-6840-410a-a563-180b86638810] [Similarity score: 0.871595] Q: 課題はどのタイミングで利用者の提出物に表示されますか？
```

```
qasystem-1 | A: 課題は、受講者のステータスが「受講予定」に変更された時点で表示されます。支払いが完了していない場合、受講者のステータスが「受講...
```

DOCXでのログ

CSVでのログ

その他の失敗例

申込者の人数制限を設定できますか？

この情報だけでは、申込者の人数制限を設定できるかどうかは判断できません。【使用したファイル】

faq_output3.json (page: 不明),

faq_output2.json (page: 不明)

失敗例

その他の原因

失敗のパターン：クエリの内容に近い単語が類似度が高くなりピックアップされるが、関係のないデータである場合が多い。

申込者の人数制限を設定できますか？



```
qasystem-1 | > [Node 40950d08-f04a-407f-b438-4198ef79a771] [Similarity: 0.85]
旅行の参加人数を当初登録から変更するにはどうすればよいですか？
qasystem-1 | A: 旅行出発日の30日前まではマイページの「団体管理」からキャンセル料が発生...
qasystem-1 | > [Node 20485a20-f59d-47d5-bd43-6c2cc5375520] [Similarity: 0.85]
・学園向け認証システムでシングルサインオンを設定する方法は？
qasystem-1 | A: 管理コンソールの「認証設定」で「SAML2.0有効化」をください。そ...
qasystem-1 | DEBUG:llama_index.core.indices.utils:> Top 2 nodes:
qasystem-1 | > [Node 6813cd0e-9930-4a75-89d0-b9d91c63f13f] [Similarity: 0.85]
ント発生時のWebhook通知は設定できますか？
qasystem-1 | A: 管理画面の「システム設定」→「Webhook管理」で、対象と通知先URLを指定すると、P...
```

運用ベストプラクティス & 結論

- DOCX, PDFなどから構造化形式（CSV、JSON等）へ統一
- VDB化する前に、元ファイルのクレンジング & スキーマ自動検出
- 構造化データにできない場合には、適切なチャンク長/オーバーラップを設計
- ファイル名などのメタデータの付与で検索文脈保持
- 単純なファイル分割ではなく、QAのカテゴリごとにファイルやディレクトリを分割することで、誤検出を減らす
- 大規模での運用は「自動前処理 + 構造化」で実装

限界と今後の課題

- データセット規模が限定的 (1000 FAQ) であり、一般化にはさらなる検証が必要。
- 埋め込みモデルや LLM の種類を変えた場合の評価は未実施。
- 固定チャンク長のため動的なチャンクサイズ調整の効果を検証できていない。
- 今後はクレンジング・スキーマ検出の自動チューニングやエラー検出機構の導入を検討。

Thank you!

ご清聴ありがとうございました

Questions?

